

Asistente Virtual IA

Asistente Virtual IA — Guía de Implementación

Sistema RAG multiidioma para consulta de manuales empresariales

Introducción

El Asistente Virtual IA es un sistema de chatbot basado en RAG (Retrieval-Augmented Generation) que permite a los usuarios consultar manuales en lenguaje natural. El sistema extrae información relevante del manual y genera respuestas precisas usando un modelo de lenguaje.

Modos disponibles:

Modo	Descripción	Uso recomendado
Producción	PDFs pre-procesados. Respuestas rápidas, índice estático.	Despliegue en cliente final
Desarrollo	Acepta cualquier PDF subido desde la web en tiempo real.	Demos y pruebas

Requisitos previos

Servidor

Recurso	Mínimo	Recomendado
CPU	2 cores	4+ cores
RAM	4 GB	8 GB
Disco	3 GB libres	5 GB libres
SO	Ubuntu 20.04+	Ubuntu 22.04+
Python	3.11	3.12

Cuentas necesarias

- **Groq API Key** (gratuita): console.groq.com

Paquetes del sistema

```
sudo apt update
sudo apt install -y git python3.11 python3.11-venv python3-pip
```

Paso 1 — Clonar el repositorio

```
git clone https://github.com/Chupacharcos/chatbot.git
cd chatbot
```

Paso 2 — Colocar los PDFs del manual

Solo necesario en **modo Producción**. En modo Desarrollo los PDFs se suben desde la web.

Copia el manual con la nomenclatura correspondiente al idioma:

```
data/manual_es.pdf ← Español (obligatorio si el cliente usa
español)
data/manual_en.pdf ← English (opcional)
data/manual_ca.pdf ← Català (opcional)
data/manual_pt.pdf ← Portugués (opcional)
```

Paso 3 — Obtener la clave de Groq

1. Regístrate en console.groq.com
 2. Ve a **API Keys** → **Create API Key**
 3. Guarda la clave (empieza por gsk_...)
-

Paso 4 — Ejecutar el instalador

```
bash setup.sh
```

El instalador realiza los siguientes pasos de forma automática:

4.1 Selección de modo

Selecciona el modo de instalación:

- 1) PRODUCCIÓN (Estático - PDFs pre-procesados)
- 2) DESARROLLO (Dinámico - Soporta PDFs desde web)

□ Opción [1-2]:

Selecciona 1 para producción o 2 para desarrollo.

4.2 Instalación de dependencias (~2 GB, 2-4 min)

Crea el entorno virtual Python e instala todas las librerías de IA: FAISS, Sentence Transformers, PyMuPDF, FastAPI, Groq, etc.

4.3 Configuración del archivo .env

Si no existe .env, el instalador lo crea de forma interactiva:

Variable	Descripción	Ejemplo
GROQ_API_KEY	Obligatoria. Clave de Groq	gsk_XXXX...
CLIENT_API_KEY	Contraseña de acceso a la API	mi_clave_segura
API_PORT	Puerto del servidor	8000
APP_URL	Origen CORS permitido	* o https://tudominio.com

Seguridad: En producción establece APP_URL al dominio exacto del cliente, no uses *.

4.4 Procesado de PDFs (solo modo Producción)

El instalador ejecuta automáticamente:

```
python3 src/process_manual.py --lang es --pdf data/manual_es.pdf
```

Este proceso: 1. Extrae el texto del PDF 2. Identifica secciones y capítulos 3. Genera chunks de texto (fragmentos) 4. Calcula embeddings con el modelo intfloat/multilingual-e5-large 5. Construye el índice FAISS y lo guarda en faiss_index/es/

La primera ejecución descarga el modelo (~500 MB). Puede tardar 5-10 minutos.

4.5 Servicio systemd

El instalador crea y activa el servicio chatbot que: - Arranca automáticamente con el servidor - Se reinicia si falla (Restart=always) - Guarda los logs en logs/api.log

4.6 HTML de demostración

Se genera chatbot_ejemplo.html con la API Key ya configurada. Abrirlo directamente en el navegador para hacer pruebas básicas.

Paso 5 — Verificación

Comprobar el servicio

```
sudo systemctl status chatbot
```

Debe mostrar: Active: active (running)

Test básico con curl

```
curl http://127.0.0.1:PUERTO/
```

Respuesta esperada:

```
{"status": "ok", "mode": "production"}
```

Test de consulta

```
curl -X POST http://127.0.0.1:PUERTO/query \
-H "Content-Type: application/json" \
-H "X-API-Key: TU_CLIENT_API_KEY" \
-d '{"question": "¿De qué trata el manual?", "lang": "es"}'
```

Gestión del servicio

sudo systemctl status chatbot	# Ver estado
sudo systemctl start chatbot	# Iniciar
sudo systemctl stop chatbot	# Detener
sudo systemctl restart chatbot	# Reiniciar tras cambios
tail -f logs/api.log	# Ver logs en tiempo real

Actualizar el manual

Cuando el cliente proporcione un nuevo PDF, procesar sin reinstalar:

```
cd /ruta/al/chatbot
source venv/bin/activate
python3 src/process_manual.py --lang es --pdf data/manual_es.pdf
sudo systemctl restart chatbot
```

Integración web

Ejemplo de integración JavaScript en la aplicación del cliente:

```
let sessionId = sessionStorage.getItem('chatbot_session_id') || '';

async function preguntar(pregunta, lang = 'es') {
  const res = await fetch('http://IP_SERVIDOR:PUERTO/query', {
    method: 'POST',
    headers: {
      'Content-Type': 'application/json',
      'X-API-Key': 'CLIENT_API_KEY'
    },
    body: JSON.stringify({ question: pregunta, lang, session_id:
sessionId })
  });

  const data = await res.json();
  sessionId = data.session_id;
  sessionStorage.setItem('chatbot_session_id', sessionId);

  return data.answer;
}
```

Referencia de la API

URL base: http://IP_DEL_SERVIDOR:PUERTO

Autenticación: cabecera X-API-Key: CLIENT_API_KEY

Método	Endpoint	Auth	Descripción
GET	/	No	Estado del servidor
POST	/upload	No	Subir PDF (modo desarrollo)
POST	/query	Sí	Consultar el manual
GET	/stats	Sí	Sesiones activas
DELETE	/history/{session_id}	Sí	Borrar historial de sesión
DELETE	/history	Sí	Borrar todo el historial
GET	/docs	No	Documentación Swagger

POST /query — Consultar

Request:

```
{
  "question": "¿Cómo se realiza el proceso de alta?",
  "lang": "es",
  "session_id": ""
}
```

Response:

```
{
  "answer": "Según el manual, el proceso consiste en...",
  "lang": "es",
  "sources": [
    {"section": "Gestión de usuarios", "page": 5, "text": "..."}
  ],
  "session_id": "alb2c3d4-..."
}
```

Idiomas soportados

Código	Idioma	PDF requerido
es	Español	data/manual_es.pdf
en	English	data/manual_en.pdf
ca	Català	data/manual_ca.pdf
pt	Português	data/manual_pt.pdf

Seguridad

- El archivo .env nunca se sube al repositorio
 - Los PDFs del cliente nunca se suben al repositorio
 - CLIENT_API_KEY protege todos los endpoints autenticados
 - APP_URL restringe CORS — en producción especificar el dominio exacto
 - Cada usuario tiene historial aislado por session_id
-

Asistente Virtual IA — Sistema RAG multiidioma